



École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes
- Rabat

Semestre 4 : Deep Learning

TP 5 : Knowledge Distillation — de la distilla

Élèves :
Jad Falaq

Enseignant :
Mme Hanaa El Afia

Année Universitaire 2025-2026

Table des matières

0.1 Introduction 2
0.2 Partie 1 – Distillation classique sur MNIST 2
0.2.1 Préparation des données et modèles 2
0.2.2 Principe de la loss KD 2
0.2.3 Résultats expérimentaux 3
0.3 Partie 2 – FitNets et RKD sur CIFAR-10 4
0.3.1 Cadre expérimental 4
0.3.2 Comparaison des méthodes 4
0.4 Conclusion 5

0.1 Introduction

Ce travail pratique porte sur la *Knowledge Distillation* (KD), une famille de méthodes permettant de transférer les connaissances d'un modèle volumineux (extitTeacher) vers un modèle compact (extitStudent). L'objectif général du TP est double : d'une part, obtenir un modèle léger déployable sur une puce IoT pour une tâche MNIST simplifiée, et d'autre part comparer des variantes plus avancées de distillation sur CIFAR-10 dans un contexte de caméra embarquée.

Le sujet est organisé en deux parties. La première traite la distillation *response-based* sur MNIST (classes 0, 1 et 8) avec un *Teacher* de type ResNet-50 et un *Student MicroCNN*. La seconde partie étudie des approches plus riches sur CIFAR-10 (chat, chien, cerf, cheval), en opposant la distillation classique à deux stratégies avancées : *FitNets* (alignement de cartes de caractéristiques) et *RKD* (préservation des relations entre représentations). Le cahier des charges insiste à chaque fois sur les contraintes de taille mémoire et de latence du modèle embarqué.

0.2 Partie 1 – Distillation classique sur MNIST

0.2.1 Préparation des données et modèles

La première étape a consisté à charger MNIST en ne conservant que les chiffres 0, 1 et 8, puis à réattribuer les étiquettes de manière compacte. Les images ont été redimensionnées en 32×32, converties en tenseurs puis normalisées. Conformément à l'énoncé, le *Teacher* a été défini à partir d'un ResNet-50 pré-entraîné dont la dernière couche a été remplacée par une couche de sortie à trois classes, tandis que le *Student* correspond à un petit *MicroCNN* composé de trois blocs convolution + batch normalization + ReLU suivis d'une couche fully connected.

L'analyse du coût des modèles montre un écart considérable entre les deux architectures. Le Teacher contient environ 23,5 millions de paramètres pour une taille d'environ 89,7 Mo, alors que le Student ne contient que 7,5 milliers de paramètres, pour une taille de 29,4 Ko. Le rapport de compression dépasse ainsi 3000×, ce qui justifie l'intérêt d'une stratégie de distillation pour l'embarqué.

0.2.2 Principe de la loss KD

La fonction de perte implémentée combine deux composantes : une *cross-entropy* classique avec les vraies étiquettes, et une divergence de Kullback-Leibler entre les distributions lissées du Teacher et du Student, pondérée par la température T et le coefficient α. Cette formulation suit directement l'énoncé du TP.

Une visualisation des *soft labels* a également été réalisée sur des exemples de chiffre 8 difficiles. Le principal constat est que lorsque $T = 1$, la distribution du Teacher est très concentrée sur une seule classe, alors qu'avec $T = 4$, elle devient plus lissée et révèle l'hésitation entre 0 et 8. Cette information relative constitue précisément le *dark knowledge* utile au Student.

0.2.3 Résultats expérimentaux

Deux expériences principales ont été menées sur 30 époques : un entraînement du Student seul, puis un entraînement avec distillation classique ($T = 4$, $\alpha = 0{,}4$). Les résultats obtenus montrent que le Student seul atteint une précision finale de 99,84%, tandis que le Student distillé atteint 99,90%. Le gain absolu reste modeste mais réel ; il est cohérent avec le fait que la tâche reste relativement simple et déjà proche de la saturation.

L'effet de la température a ensuite été étudié pour $T \in \{1, 2, 4, 8\}$ en fixant $\alpha = 0{,}4$. Les meilleures précisions sont observées pour $T = 2$ et $T = 4$ (toutes deux à 99,90%), alors que $T = 1$ et $T = 8$ donnent 99,84%. On peut en déduire qu'une température intermédiaire fournit le meilleur compromis : elle lisse suffisamment les distributions pour faire ressortir la similarité entre 0 et 8, sans trop diluer l'information utile.

Une troisième série d'expériences a comparé trois régimes de Student (grand, moyen, petit) avec et sans KD. Les résultats montrent des écarts très faibles : le grand Student passe de 99,90% à 99,97%, le modèle moyen de 99,94% à 99,90%, et le petit Student reste à 99,71% dans les deux cas. Dans ce notebook, le régime observé est donc globalement *neutre* : la KD n'apporte pas d'amélioration spectaculaire mais stabilise légèrement certains cas.

Enfin, une variante *Attention Transfer* (AT) a été ajoutée à la loss de distillation, avec extraction des *feature maps* via `register_forward_hook`. Le modèle *Student + KD + AT* obtient une précision finale de 99,84%, très proche des autres variantes. Sur cette partie, la conclusion pratique est surtout matérielle : le Student, avec ou sans KD, respecte très largement les contraintes d'embarqué, avec une latence moyenne d'environ 0,49 ms et une taille de seulement 29,4 Ko. À l'inverse, le Teacher reste beaucoup trop volumineux pour une puce IoT. Le sujet demandait justement d'évaluer les approches response-based, l'effet de T, les régimes de distillation et l'ajout d'Attention Transfer.

Table 1 – Synthèse des résultats obtenus sur MNIST

Modèle	Taille	Latence	Précision
Teacher (ResNet-50)	89.7 Mo	5.25 ms	33.96%
Student seul	29.4 Ko	0.49 ms	99.84%
Student + KD	29.4 Ko	0.49 ms	99.90%
Student + KD + AT	29.4 Ko	0.49 ms	99.84%

Remarque critique. Les précisions très faibles mesurées pour les Teachers (33.96% sur MNIST et 30.28% sur CIFAR-10) indiquent que, dans le notebook, ces modèles ont bien été adaptés en sortie mais n'ont pas été réellement fine-tunés sur les nouvelles classes. Cela n'empêche pas de valider la structure du TP et les comparaisons entre Students, mais il faut le mentionner honnêtement dans le rapport.

0.3 Partie 2 – FitNets et RKD sur CIFAR-10

0.3.1 Cadre expérimental

Dans la deuxième partie, le dataset CIFAR-10 a été filtré pour ne conserver que quatre classes visuellement proches : chat, chien, cerf et cheval. Les données d'entraînement ont subi une normalisation standard ainsi qu'un retournement horizontal aléatoire. Le *Teacher* est un VGG-16 pré-entraîné, alors que le *Student* est un *TinyCNN* composé de quatre couches convolutionnelles avec batch normalization, activations ReLU et opérations de max-pooling. L'objectif annoncé par l'énoncé est de comparer la distillation classique à deux variantes avancées : *Feature-Based KD / FitNets* et *Relation-Based KD / RKD*. Le Teacher VGG-16 contient environ 134,3 millions de paramètres et occupe plus de 512 Mo dans le notebook, alors que le TinyCNN ne contient qu'environ 130,7 milliers de paramètres pour une taille de 0,50 Mo. Le Student satisfait donc très largement la contrainte de moins de 200 000 paramètres.

0.3.2 Comparaison des méthodes

La première référence est l'entraînement du Student sans distillation, qui atteint une précision finale de 81,77%. La KD classique ($T = 4$, $\alpha = 0{,}4$) obtient ici 76,53%, soit un résultat inférieur à l'entraînement direct. Dans cette implémentation précise, la response-based KD ne constitue donc pas la meilleure stratégie sur CIFAR-10.

La méthode *FitNets* a ensuite été mise en place en alignant une couche intermédiaire du Student sur une couche du Teacher à l'aide d'une convolution 1×1 d'adaptation. Trois valeurs de γ ont été testées : 0,1, 0,5 et 1,0. Les précisions finales obtenues sont respectivement 75,33%, 68,55% et 75,72%. On constate que $\gamma = 0{,}5$ dégrade nettement les performances, tandis que $\gamma = 1{,}0$ redonne le meilleur résultat parmi les variantes FitNets, sans toutefois dépasser le Student seul.

La méthode *RKD* a enfin été étudiée à travers trois configurations : distance seule, angle seul, puis combinaison distance + angle. Les précisions finales sont de 75,05%, 75,20% et 76,85%. La version combinée est la plus performante parmi les variantes de distillation avancée. Les visualisations qualitatives du notebook vont d'ailleurs dans le même sens : les *heatmaps* de FitNets montrent un meilleur alignement des zones saillantes, et l'analyse t-SNE indique que RKD reproduit mieux la topologie relationnelle du Teacher, notamment la proximité chat/chien et cerf/cheval.

Du point de vue embarqué, tous les Students testés restent compatibles avec la contrainte matérielle de la caméra : environ 0,50 Mo de taille et 0,60 ms de latence. Si l'on se base strictement sur les résultats obtenus dans le notebook, le meilleur compromis précision/complexité reste le *Student seul* avec 81,77%, devant RKD combiné (76,85%), la KD classique (76,53%) et FitNets (75,72%).

TABLE 2 – Synthèse des résultats obtenus sur CIFAR-10

Modèle	Taille	Latence	Précision
Teacher (VGG-16)	512.2 Mo	4.72 ms	30.28%
Student seul	0.50 Mo	0.59 ms	81.77%
Student + KD (réf.)	0.50 Mo	0.60 ms	76.53%
Student + FitNets	0.50 Mo	0.60 ms	75.72%
Student + RKD combiné	0.50 Mo	0.60 ms	76.85%

0.4 Conclusion

Ce TP a permis de mettre en pratique plusieurs variantes de Knowledge Distillation dans deux contextes différents. Sur MNIST, la distillation classique améliore légèrement le Student tout en conservant une empreinte mémoire et une latence extrêmement faibles ; les températures intermédiaires se révèlent les plus intéressantes, car elles traduisent mieux les ambiguïtés entre classes proches. Sur CIFAR-10, les méthodes avancées FitNets et RKD apportent surtout un intérêt analytique : FitNets améliore l'alignement des représentations intermédiaires, tandis que RKD conserve mieux les relations géométriques entre exemples. Toutefois, dans les résultats réellement obtenus dans le notebook, le meilleur modèle à déployer reste le TinyCNN entraîné seul, car il fournit la meilleure précision tout en respectant largement les contraintes matérielles.

En résumé, la Knowledge Distillation reste une approche très pertinente pour l'embarqué, mais son efficacité dépend fortement de la qualité du Teacher, du choix des hyperparamètres et de l'adéquation entre la méthode de distillation et la tâche étudiée. Dans ce TP, le point le plus important n'est donc pas seulement le score final, mais la compréhension progressive des mécanismes de transfert de connaissance : soft labels, cartes d'attention, alignement de features et préservation des relations inter-classes.