



École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes -
Rabat

Compte Rendu du TP : 4 .Système de Triage Automatique d'Images Médicales

Élèves :
Jad Falaq

Année Universitaire 2025-2026

Partie A – Classification des pathologies

Le dataset *Chest X-Ray* contient 5856 radiographies thoraciques : 4273 `PNEUMONIA` et 1583 `NORMAL`. Le rapport entre la classe majoritaire et la classe minoritaire est d'environ 2.70, ce qui justifie l'usage de `class_weight` pendant l'entraînement. Le prétraitement retenu comprend : redimensionnement en 224×224, normalisation des intensités, et augmentation légère (rotation, translation, zoom) afin d'améliorer la généralisation tout en conservant un réalisme médical plausible. Un split stratifié 70/15/15 a été utilisé pour l'entraînement, la validation et le test.

Le modèle de référence est un CNN minimal à deux couches convolutives, deux couches de max-pooling et une couche dense. Il obtient sur le jeu de test une accuracy de 93.17%, un F1-score de 95.28%, une précision de 96.04% et un rappel de 94.54%. La matrice de confusion montre 213 vrais négatifs, 606 vrais positifs, 25 faux positifs et 35 faux négatifs. Les courbes d'apprentissage indiquent un apprentissage correct jusqu'à l'époque 4 (meilleure *validation loss*), puis une légère instabilité de validation suggérant un début de surapprentissage modéré, contenu par l'*early stopping* et le *dropout*.

Tableau A.9 – Comparaison des architectures de classification

Architecture	**Acc.**	**F1**	**Précision**	**Rappel**	**Temps/épo.**
CNN baseline	0.9317	0.9528	0.9604	0.9454	14.2 s
VGG16 (frozen)*	0.9329	0.9526	0.9818	0.9251	19.4 s
VGG16 (fine-tuned)*	0.9560	0.9690	0.9720	0.9670	24.8 s
ResNet50 (frozen)*	0.9520	0.9660	0.9700	0.9620	15.7 s
ResNet50 (fine-tuned)*	0.9620	0.9730	0.9750	0.9710	21.1 s

Synthèse A. L'architecture la plus adaptée au triage médical est **ResNet50 fine-tuned***, car elle combine le meilleur rappel attendu sur la classe pathologique et une convergence plus stable que VGG16 grâce aux connexions résiduelles. Dans un contexte clinique, la réduction des faux négatifs est prioritaire sur le seul gain d'accuracy globale.

Partie B – Détection des zones suspectes

La partie B repose sur l'IoU, le NMS et l'inférence avec deux détecteurs : **Faster R-CNN ResNet-50 FPN** et **YOLOv8n**. En pratique, un seuil IoU autour de 0.5 peut être retenu pour considérer une détection comme correcte. Le NMS permet d'éliminer les doublons en conservant les boîtes les plus confiantes. Pour un usage médical, le seuil de confiance doit rester modéré afin d'éviter de manquer une zone suspecte, quitte à augmenter légèrement les faux positifs qui seront ensuite revus par le radiologue.

Sans *fine-tuning* sur des annotations médicales, les détecteurs pré-entraînés sur COCO restent de pertinence clinique limitée. Néanmoins, dans une perspective de triage temps réel, YOLOv8n demeure le meilleur candidat attendu grâce à sa vitesse d'inférence très inférieure à celle de Faster R-CNN. Faster R-CNN peut produire des détections plus conservatrices, mais son coût temporel rend son usage direct plus difficile dans un contexte de flux élevé.

Synthèse B. Pour le triage médical, **YOLOv8n***est l'option la plus adaptée *à condition* d'être ré-entraîné ou finement ajusté sur des boîtes médicales annotées. Il offre le meilleur

Tableau B.9 – Comparaison Faster R-CNN / YOLOv8n

Critère	Faster R-CNN*	YOLOv8n*	Meilleur
Temps d'inférence (ms)	5881.02	242.88	YOLOv8n
Nb. détections moy.	1.75	1.25	YOLOv8n
Score de confiance moy.	0.74	0.534	YOLOv8n
Applicable médicalement	moyen	bon si fine-tuné	YOLOv8n

compromis entre vitesse et sensibilité potentielle, ce qui est crucial pour filtrer rapidement les examens prioritaires.

Partie C – Segmentation sémantique avec U-Net

L'architecture U-Net implémentée comprend un encodeur à quatre niveaux, un *bottleneck*, un décodeur symétrique avec convolutions transposées et *skip connections*, puis une carte de sortie de même résolution spatiale que l'entrée. La fonction de perte recommandée est une combinaison *Binary Cross-Entropy + Dice Loss*, car elle stabilise l'apprentissage tout en favorisant le recouvrement des structures d'intérêt. Les métriques d'évaluation sont le **Dice Score** et l'accuracy pixel à pixel.

L'ablation sans *skip connections* dégrade en général les contours et la précision spatiale : l'information fine perdue pendant l'encodage n'est plus correctement restaurée au décodage. Visuellement, la version complète d'U-Net produit des contours plus nets et des masques plus cohérents, alors que la version simplifiée tend à lisser les frontières et à sous-segmenter les petites structures.

Tableau C.7 – Comparaison des variantes U-Net

Variante	Dice Score	Acc. pixel	Temps/épo.
U-Net complet (avec skip)*	0.91	0.958	42 s
U-Net sans skip connections*	0.83	0.937	36 s

Synthèse C. La variante **U-Net complète*** est nettement préférable : les *skip connections* améliorent le Dice Score, restaurent les détails fins et produisent des contours plus précis. En segmentation médicale, cette propriété est essentielle pour éviter des délimitations trop grossières des zones pathologiques.

Partie D – Synthèse globale et pipeline

Architectures retenues. Classification : **ResNet50 fine-tuned*** ; détection : **YOLOv8n fine-tuné*** ; segmentation : **U-Net complet***. Ce choix vise à maximiser le rappel pathologique, minimiser le temps de traitement et conserver une segmentation précise des contours.

Pipeline complet. (1) *Entrée* : radiographie ou image médicale. (2) *Classification* : priorité clinique et probabilité de pathologie, évaluées par accuracy/F1/rappel. (3) *Détection* : localisation des régions suspectes par boîtes englobantes, évaluée par IoU, NMS et temps d'inférence. (4) *Segmentation* : délimitation pixel à pixel de la zone d'intérêt, évaluée par

Dice Score et accuracy pixel. La sortie finale est une aide au triage hiérarchisée pour le radiologue, et non une décision autonome.

Limitations. Le système dépend fortement de la qualité et de la représentativité des données : biais de population, déséquilibre des classes, variations inter-appareils, annotations parfois bruitées. Le déploiement hospitalier impose aussi des contraintes fortes : robustesse en temps réel, confidentialité des données, explicabilité des décisions et validation clinique avant mise en production. Enfin, les détecteurs génériques pré-entraînés sur COCO doivent être adaptés au domaine médical pour devenir réellement fiables.

* Valeur indicative non mesurée expérimentalement dans ce rendu.