

École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes
- Rabat

Compte Rendu du Travaux Pratique TP2

Développement d'un Perceptron Multicouche (MLP) pour des Problèmes Supervisés

Élèves :
Jad Falaq

Enseignant :
Hanaa El Afia

Table des matières

1 Régression : Prédiction de la consommation énergétique **2**

2 Classification multiclasse : Prédiction de la maladie **2**

3 Classification binaire : Détection de fraude **3**

1 Régression : Prédiction de la consommation énergétique

L'objectif est de prédire simultanément *Heating_Load* et *Cooling_Load* à partir de 8 caractéristiques architecturales du bâtiment. Le jeu de données contient 768 instances sans valeurs manquantes. L'analyse de corrélation montre une forte dépendance entre les deux variables cibles ($r = 0.98$), justifiant l'utilisation d'un modèle multi-sortie.

Les variables d'entrée ont été standardisées (Z-score) en utilisant uniquement l'ensemble d'entraînement. Les données ont été divisées en 68% pour l'entraînement, 12% pour la validation et 20% pour le test.

Le modèle utilisé est un perceptron multicouche composé de deux couches cachées de 64 et 32 neurones avec activation ReLU et Dropout (0.1). La fonction de perte est la MSE et l'optimisation est réalisée avec Adam. Un *early stopping* basé sur l'erreur de validation a été appliqué pour limiter le surapprentissage.

Les performances obtenues sur l'ensemble de test sont les suivantes :

Variable	MAE	RMSE	R^2
Heating_Load	0.059	0.078	0.994
Cooling_Load	0.106	0.146	0.979

Les courbes d'apprentissage montrent une convergence stable sans surapprentissage. Les prédictions sont fortement alignées avec les valeurs réelles et les résidus sont centrés autour de zéro, indiquant un modèle non biaisé avec une excellente capacité de généralisation.

Ces performances élevées s'expliquent par la forte corrélation entre les variables géométriques et les charges thermiques ainsi que par la nature structurée du jeu de données. L'erreur légèrement plus élevée pour le refroidissement est liée à des phénomènes thermiques plus complexes.

Limites et amélioration : les résultats sont obtenus sur des données simulées et fortement corrélées. Sur des données réelles plus bruitées, l'utilisation de techniques de régularisation supplémentaires ou d'une validation croisée pourrait améliorer la robustesse du modèle.

2 Classification multiclasse : Prédiction de la maladie

L'objectif est de prédire la pathologie parmi 30 classes à partir de variables démographiques et de symptômes encodés en one-hot. Le jeu de données contient 25 000 observations et 33 variables d'entrée après prétraitement. Les données ont été divisées en ensembles d'entraînement (80%), validation (10%) et test (10%). Les variables numériques ont été standardisées à partir de l'ensemble d'entraînement uniquement.

Le modèle utilisé est un perceptron multicouche comportant trois couches cachées (256, 128 et 64 neurones) avec fonctions d'activation ReLU, Batch Normalization et Dropout (0.1). L'optimisation est réalisée avec Adam et la fonction de perte est l'entropie croisée.

Les performances obtenues sur l'ensemble de test sont résumées dans le tableau suivant :

Accuracy	F1-macro
0.036	0.005

Afin de vérifier la validité du pipeline d'apprentissage, une expérience de sur-apprentissage sur un sous-ensemble de 500 observations a été réalisée. Le modèle atteint 100% d'accuracy, ce qui confirme que l'architecture et la procédure d'entraînement sont correctes. Les faibles performances en généralisation ne proviennent donc pas du modèle mais des données.

Cette limitation s'explique par le faible nombre de symptômes actifs par individu et par le recouvrement important des symptômes entre plusieurs maladies, rendant la séparation des classes difficile avec les variables disponibles. Le problème présente ainsi une forte ambiguïté intrinsèque et un faible pouvoir discriminant.

Pistes d'amélioration :

— enrichir la représentation des symptômes (pondération de type TF-IDF, nouvelles variables cliniques) ;
— regrouper les maladies en catégories médicales pour réduire la complexité ;
— reformuler le problème en classification multi-label plus adaptée au contexte médical.

3 Classification binaire : Détection de fraude

L'objectif est de prédire si une transaction est *normale* ou *frauduleuse* à partir de variables transactionnelles (montant, caractéristiques temporelles, type d'opération et localisation). Après transformation de la variable cible en problème binaire, les variables catégorielles ont été encodées par *one-hot encoding*. Le montant, fortement asymétrique, a été transformé par $\log(1+x)$ puis standardisé. Les données ont été divisées de manière stratifiée en ensembles d'entraînement, validation et test.

Le modèle utilisé est un perceptron multicouche à trois couches cachées (128, 64 et 32 neurones, ReLU, Dropout). L'optimisation est réalisée avec Adam et la fonction de perte pondérée (*BCEWithLogitsLoss*) a été utilisée pour tenir compte du déséquilibre de classes.

Les performances sur l'ensemble de test sont :

Accuracy	Précision	Recall fraude	F1-score	ROC-AUC
0.83	0.86	0.84	0.88	0.84

Le modèle détecte 88% des fraudes avec un nombre limité de faux négatifs (20), ce qui est crucial en contexte bancaire. Le rappel élevé est obtenu au prix d'un nombre plus important de faux positifs, choix généralement acceptable en détection de fraude. Les courbes d'apprentissage montrent un surapprentissage modéré contrôlé par l'early stopping.

Limites et améliorations : l'ajustement du seuil de décision permettrait d'augmenter la précision sans dégrader significativement le rappel. L'ajout de nouvelles variables comportementales ou l'utilisation de techniques d'ensemble pourrait améliorer les performances.